

Modelo espacial temporal del riesgo de cáncer de mama en México

Familia Knorr-Held (1999/2000): base + 4 tipos de interacción

Incidencia de cáncer de mama, 32 entidades, 2003–2024

Manuel McCadden José Diego Martínez Diego Adabache Diego Cottin

Regresión Avanzada, ITAM

Mayo 2026

1. Planteamiento del problema

Se modela la **incidencia de cáncer de mama** en las $S = 32$ entidades federativas de México durante $T = 22$ años (2003–2024), un panel de $S \times T = 704$ celdas estado–año. Para cada celda se observa el número de casos $y_{s,t}$ y un número de casos esperados $E_{s,t}$ (offset), construido a partir de la población femenina estatal y una tasa de referencia. **Se supone que los casos siguen una distribución de Poisson:**

$$y_{s,t} \sim \text{Poisson}(\mu_{s,t}), \quad \mu_{s,t} = E_{s,t} \lambda_{s,t},$$

donde $\lambda_{s,t}$ es el **riesgo relativo** de la celda (el objeto que el modelo estima y suaviza); todo el modelado actúa sobre $\log \lambda_{s,t}$. El cociente crudo $\text{SMR}_{s,t} = y_{s,t}/E_{s,t}$ es la **razón de incidencia estandarizada** (*standardized incidence ratio*): casos observados entre casos esperados bajo la tasa promedio del periodo. Es adimensional y está centrada en 1: $\text{SMR} = 1$ significa riesgo igual al promedio nacional 2003–2024, $\text{SMR} = 2$ el doble, $\text{SMR} = 0,5$ la mitad. Es la estimación *cruda* del riesgo relativo de cada celda, la que el modelo suaviza ($\hat{\lambda}_{s,t}$ es su versión encogida). Los conteos cubren un rango amplio ($y \in [4, 7301]$, $E \in [56, 2, 2194]$): hay entidades-año con poquísimos casos (donde uno o dos casos de diferencia cambian la tasa radicalmente) y entidades-año con miles. Esa disparidad de tamaño es el problema central de mapeo de enfermedades: las tasas crudas de las celdas pequeñas son ruido, no señal.

El marco de Knorr-Held descompone el log-riesgo en efectos principales *separables* más un término de *interacción* no separable:

$$\log \lambda_{s,t} = \alpha + \phi_s + \theta_s + \gamma_t \ [+ \delta_{s,t}].$$

Los corchetes alrededor de $\delta_{s,t}$ indican que ese término está *ausente* en el modelo base y *presente* en los cuatro modelos de interacción; el resto del predictor es idéntico en los cinco. Los efectos principales obligan al mapa espacial a tener forma fija en el tiempo (ϕ_s, θ_s) y a la tendencia temporal a ser la misma en todos los estados (γ_t). La pregunta sustantiva del proyecto es **si esa separabilidad se sostiene en los datos mexicanos**: ¿la incidencia de cáncer de mama subió de forma pareja en todo el país, o cada estado tuvo su propia trayectoria? El caso de interés concreto: la incidencia es *registrada*, y un estado que amplía su programa de tamizaje (mastografía) en cierto año detecta y registra más casos a partir de entonces, aunque el riesgo subyacente no cambie; si cada estado expande el tamizaje en momentos distintos, sus curvas no son paralelas. El término $\delta_{s,t}$ es la parte del riesgo que la aditividad *no* puede representar, y los cuatro tipos de Knorr-Held son cuatro hipótesis sobre su estructura: ruido puro (I), dinámica propia por estado (II), mapa anual sin memoria (III) o un mapa que evoluciona suavemente (IV).

Relación con Knorr-Held (1999). Este proyecto es, deliberadamente, una *reproducción casi literal* del Paper 147 del SFB 386, *Bayesian Modelling of Inseparable Space–Time Variation in*

Disease Risk (L. Knorr-Held, 1999). Se reproduce su marco completo: verosimilitud Poisson con offset, predictor aditivo $\alpha + \phi_s + \theta_s + \gamma_t$, los cuatro tipos de interacción $\delta_{s,t}$ como producto de Kronecker de una estructura espacial por una temporal (§2.2 del paper), las restricciones de identificabilidad por recentrado (§2.4) y la comparación de modelos por DIC (*Deviance Information Criterion*, §3). El cambio central es el **conjunto de datos**: donde Knorr-Held analiza *mortalidad por cáncer de pulmón* en los 88 condados de Ohio, 1968–1988 (21 años), nosotros analizamos *incidencia de cáncer de mama* en las 32 entidades de México, 2003–2024 (22 años). La única extensión es ajustar además tres modelos reducidos para aislar el aporte de cada bloque, en la línea de su §2.5. El objetivo es exactamente el suyo: dejar que la devianza y los diagnósticos de convergencia decidan qué hipótesis de (in)separabilidad sostienen los datos. La única desviación metodológica es de implementación (CAR (*Conditional Autoregressive*) intrínseco estimado por MCMC (*Markov chain Monte Carlo*) en vez del muestreador Metropolis univariado del autor) y el resultado sustantivo, como se verá, resulta *opuesto* al de Ohio: ahí ganó la interacción estructurada Tipo II; aquí gana la no estructurada Tipo I.

Se ajustan ocho modelos por MCMC. Cinco forman la familia Knorr-Held: el base sin interacción y los cuatro tipos de interacción. Los otros tres son reducidos y anidados, sólo intercepto, sólo tendencia temporal y sólo estructura espacial; sirven para cuantificar el aporte de cada bloque principal. Los ocho comparten la misma verosimilitud Poisson con offset, el efecto espacial CAR intrínseco, la tendencia temporal RW1 (*caminata aleatoria de orden 1*) y la convolución BYM (*Besag-York-Mollié*), con las restricciones de identificabilidad fieles al paper. La convergencia, el DIC y los resúmenes posteriores se calculan de las cadenas MCMC finales. El criterio de comparación es la distribución posterior de la devianza, complementada con el DIC ($p_D = \frac{1}{2}\text{Var}(D)$, $\text{DIC} = \bar{D} + p_D$), como en Knorr-Held.

2. Datos

El panel modelado tiene 704 celdas (una por entidad federativa y año, 32×22) y combina tres fuentes.

1. Incidencia de cáncer de mama. Tasas de incidencia *registrada* por 100,000 mujeres, por entidad federativa, año (2003–2024) y grupo de edad. Se usa la tasa cruda por entidad-año, toda edad (p.ej. Aguascalientes 2003: 23,81 por 100,000). Al ser incidencia *registrada*, depende de la cobertura de detección y de la calidad del registro de cada entidad, un punto central en la interpretación: la maduración del tamizaje mastográfico explica el crecimiento $\times 4,42$ observado, no un aumento real del riesgo basal.

2. Población femenina (INEGI). Población femenina por entidad y grupo quinquenal de edad de los Censos de Población y Vivienda 2000, 2010 y 2020 y el Censo 2005. La población de cada celda estado-año se obtiene por *interpolación lineal* entre años censales y *extrapolación* para 2021–2024 (p.ej. Aguascalientes pasa de 525,132 mujeres en 2003 a 608,358 en 2010 y 777,150 en 2024). El rango poblacional es amplio (233,646 a 9,126,022 mujeres), lo que genera la disparidad de tamaño que motiva todo el enfoque jerárquico.

3. Geografía. Una matriz de adyacencia 32×32 (binaria, simétrica) define los vecinos espaciales $\mathbf{W}$ que alimentan el CAR; el grado de vecindad va de 1 (Baja California Sur) a 8, sin entidades aisladas.

Construcción de y y E (estandarización indirecta interna). Para cada celda, los casos observados son la tasa por la población,

$$y_{s,t} = \left[\frac{r_{s,t}}{10^5} \cdot N_{s,t} \right], \quad E_{s,t} = \bar{r} \cdot \frac{N_{s,t}}{10^5}, \quad \text{SMR}_{s,t} = \frac{y_{s,t}}{E_{s,t}},$$

donde $r_{s,t}$ es la tasa registrada, $N_{s,t}$ la población femenina, $[\cdot]$ redondeo, y $\bar{r} = 24,04$ casos por 100,000 mujeres es una *tasa de referencia única*, igual a la incidencia global del periodo $(\sum_{s,t} y_{s,t} / \sum_{s,t} N_{s,t}) \times 10^5$ (constante en las 704 celdas). Es decir, $E_{s,t}$ es el número de casos que cada entidad-año tendría bajo la tasa promedio nacional del periodo: una **estandarización indirecta interna**. En consecuencia $SMR_{s,t} > 1$ significa riesgo por encima del promedio mexicano 2003–2024, no respecto a una referencia externa. Como el offset usa una tasa fija, el crecimiento temporal real del riesgo *no* está absorbido por E y queda por estimar en γ_t (de ahí que $\sum_s y_{s,t} / \sum_s E_{s,t}$ nacional suba de 0,51 a 2,13).

Esta es la misma lógica de Knorr-Held (§2.1, casos esperados como offset); la diferencia es que sus E de Ohio están estandarizados por edad con una referencia poblacional externa, mientras aquí se usa estandarización interna por no disponer de una tasa de referencia externa por edad para México en todo el periodo.

3. Análisis exploratorio de datos




Figura 1: Izquierda: tasa cruda por 100,000 mujeres de las 32 entidades (gris) y media nacional (rojo). Derecha: razón observado/esperado nacional $\sum_s y_{s,t} / \sum_s E_{s,t}$ por año.

La incidencia registrada de cáncer de mama en México **se multiplicó por más de cuatro** en el periodo: la tasa media nacional pasó de 12,3 a 53,8 por 100,000 mujeres entre 2003 y 2024, y la razón observado/esperado nacional subió de 0,506 (2003) a 2,126 (2024). El offset $E_{s,t}$ está claramente calibrado a una referencia de mitad de periodo: por eso los primeros años tienen $\sum_s y_{s,t} / \sum_s E_{s,t} < 1$ y los últimos > 2 . Esto no es un brote: es la maduración del registro y del tamizaje mastográfico (más cobertura, más detección, mejor codificación). Hay una **caída visible en 2020** ($\sum_s y_{s,t} / \sum_s E_{s,t}$ baja a 0,951 desde 1,17 en 2019) seguida de un rebote a 1,235 en 2021: la firma del subdiagnóstico por la pandemia de COVID-19, cuando se interrumpieron tamizajes y consultas. El abanico de curvas grises se abre con el tiempo: la dispersión entre estados *crece*, lo que ya anticipa que un modelo de curvas paralelas (separabilidad estricta) será insuficiente.




Figura 2: Ruido Poisson y heterogeneidad. Izquierda: SMR vs. casos esperados E (escala log). Centro: distribución de la SMR cruda. Derecha: dispersión de la SMR por año.

El panel izquierdo es el argumento empírico para todo el enfoque jerárquico: la dispersión de la SMR disminuye al crecer E . Las entidades-año con E chico producen SMR desde ≈ 0 hasta 7,28 (el máximo es Colima 2024, con tasa cruda de 175 por 100,000) simplemente por ruido de conteo; las de E grande se apretujan alrededor de 1. Estimar el riesgo con la tasa cruda equivale a creer que Colima tiene siete veces el riesgo nacional, cuando lo que tiene es un denominador pequeño. La distribución de SMR es muy asimétrica con cola derecha larga, y el diagrama de cajas por año muestra que la *varianza* entre estados crece sostenidamente: es heterogeneidad real más sobredispersión Poisson, no un nivel que sube parejo.




Figura 3: SMR cruda en cuatro cortes (2003, 2010, 2017, 2024). Cortes por cuantiles, escala roja.

Los mapas crudos muestran un gradiente persistente: el **centro-occidente y el norte** (Colima, Aguascalientes, Jalisco, las Bajas Californias) concentran SMR alta, mientras el **sureste y el sur pobre** (Chiapas, Guerrero, Oaxaca, Quintana Roo, Tabasco) quedan por debajo. Es el patrón epidemiológico esperado del cáncer de mama: mayor incidencia donde hay más urbanización, mayor edad reproductiva tardía y mejor acceso a diagnóstico; menor donde el registro y el tamizaje son más débiles. Pero el patrón se vuelve más *ruidoso* y saturado con los años (2024 mucho más extremo que 2003), otra señal de que la forma del mapa no es fija: hay interacción espacio-tiempo.

4. Especificación de los modelos

Verosimilitud (idéntica en los cinco). Poisson con offset:

$$y_{s,t} \sim \text{Poisson}(\mu_{s,t}), \quad \mu_{s,t} = E_{s,t} \lambda_{s,t}, \quad \log \lambda_{s,t} = \alpha + \phi_s + \theta_s + \gamma_t [+ \delta_{s,t}].$$

Componentes compartidos. Intercepto $\alpha \sim \mathcal{N}(0, 10^2)$; efecto espacial estructurado ϕ con CAR intrínseco $\phi \sim \text{ICAR}(\tau_\phi)$ (*intrinsic* CAR; véase la nota más abajo) sobre la adyacencia $\mathbf{W}$ de los 32 estados (CAR intrínseco, suma-cero); heterogeneidad no estructurada $\theta_s \sim \mathcal{N}(0, \tau_\theta^{-1})$ centrada (junto a ϕ forma la convolución **BYM**); tendencia temporal RW1 $\gamma_t \sim \mathcal{N}(\gamma_{t-1}, \tau_\gamma^{-1})$ centrada. Hiperpriors $\tau_\bullet \sim \text{Gamma}(1, 0, 1)$ (informativas, media 10: aceleran la mezcla respecto a la difusa $\text{Gamma}(0, 001, 0, 001)$, decisión documentada en la bitácora de convergencia y consistente con la nota de Knorr-Held §2.3 sobre el efecto de hiperpriors difusas en la autocorrelación).

Cómo cada coeficiente mueve $\mu_{s,t}$

Como $\log \lambda_{s,t}$ es la suma de los coeficientes y $\mu_{s,t} = E_{s,t} \exp(\alpha + \phi_s + \theta_s + \gamma_t + \delta_{s,t})$, cada término entra **multiplicativamente**: si un coeficiente crece en Δ , μ se multiplica por $\exp(\Delta)$ en las celdas afectadas.

Δ	$\exp(\Delta)$	cambio en μ	en una celda con $\mu = 200$
+0,05	1,051	+5,1 %	→ 210
+0,10	1,105	+10,5 %	→ 221
+0,50	1,649	+65 %	→ 330
+1,00	2,718	+172 %	→ 544

Qué celdas afecta cada coeficiente cuando crece en Δ :

- α (intercepto global): μ se multiplica por $\exp(\Delta)$ en *las 704 celdas*. Mueve el nivel base; no diferencia entidades ni años.
- γ_t (tendencia anual): μ se multiplica por $\exp(\Delta)$ en *los 32 estados de ese año t* . Un solo año mueve 32 celdas a la vez.
- $\phi_s + \theta_s$ (nivel espacial): μ se multiplica por $\exp(\Delta)$ en *los 22 años del estado s* . Un solo estado mueve 22 celdas.
- $\delta_{s,t}$ (interacción): μ se multiplica por $\exp(\Delta)$ en *una sola celda (s, t)* . No se propaga.

Identificabilidad. α , γ_t y $\delta_{s,t}$ están centrados (suma-cero, ver §2.4 del paper) para que “ $+\Delta$ a α y $-\Delta$ a γ_t ” no produzca la misma μ . En la pareja BYM sólo la suma $\phi_s + \theta_s$ está identificada; el reparto suave/ruido lo fija el prior (siguiente nota).

ϕ_s y θ_s : sólo la suma se identifica. En el predictor el espacio entra únicamente como $\phi_s + \theta_s$, así que sumar una constante a ϕ_s y restarla a θ_s deja $\log \lambda_{s,t}$ y la verosimilitud inalteradas. Los datos informan la suma (el nivel espacial total de cada estado), no el reparto entre sus dos partes; ese reparto lo fija el *prior*, no la evidencia. La diferencia entre ϕ_s y θ_s está precisamente en ese prior: ϕ_s es *estructurado* (CAR/ICAR, amarrado a los vecinos) y captura el patrón regional suave (centro-occidente/norte alto vs. sureste bajo); $\theta_s \sim \mathcal{N}(0, \tau_\theta^{-1})$ es ruido por estado sin patrón geográfico. Es la misma distinción que separa la interacción no estructurada (Tipo I) de las estructuradas (II–IV): “¿la desviación es ruido o patrón suave?” Consecuencia práctica: τ_ϕ y τ_θ intercambian varianza y mezclan mal (la no identificabilidad BYM que reaparece en la convergencia de todos los modelos), pero la inferencia sobre $\lambda_{s,t}$ y sobre la suma $\exp(\phi_s + \theta_s)$ es robusta. Por eso **se reporta sólo el efecto espacial total** $\exp(\phi_s + \theta_s)$, nunca ϕ_s ni θ_s por separado.

Nota: ¿qué es el CAR intrínseco (ICAR)?

El CAR *propio* usa la matriz de precisión $\mathbf{Q}_\phi = \tau_\phi(\mathbf{D} - \rho\mathbf{W})$, donde $\mathbf{D}$ es diagonal con el número de vecinos, $\mathbf{W}$ la adyacencia y $\rho \in (0, 1)$ un parámetro de fuerza espacial que mantiene $\mathbf{Q}_\phi$ invertible (distribución propia). El **ICAR** (*intrinsic* CAR) es el caso límite $\rho \rightarrow 1$, que es exactamente el prior espacial que usa Knorr-Held (§2.2, “Gaussian intrinsic autoregression” de Besag et al.). Su densidad no se escribe por la conjunta sino por las *condicionales completas*: cada efecto es, a priori, la media de sus vecinos con precisión proporcional a cuántos tiene,

$$\phi_s \mid \phi_{-s} \sim \mathcal{N}\left(\frac{1}{d_s} \sum_{r \sim s} \phi_r, (\tau_\phi d_s)^{-1}\right),$$

equivalente a la forma de pares $p(\phi) \propto \exp\left(-\frac{\tau_\phi}{2} \sum_{s \sim r} (\phi_s - \phi_r)^2\right)$. Es el **análogo espacial exacto de la caminata aleatoria RW1** que sí vimos en tiempo: RW1 penaliza diferencias entre años *contiguos*; ICAR penaliza diferencias entre estados *vecinos*. Tres consecuencias prácticas: (i) no estima ρ (un parámetro menos: suaviza “al máximo” respetando el grafo); (ii) la matriz de precisión es *singular* (rango $S - 1$), por lo que el prior es impropio y *requiere* la restricción suma-cero $\sum_s \phi_s = 0$ (el prior se impone con media cero) y por eso aparece la confusión de identificabilidad con el intercepto y con θ_s que domina los diagnósticos de convergencia (§5); (iii) es el prior *fiel al paper*: elegirlo es parte de “reproducir Knorr-Held”, no una decisión nuestra. La misma idea ICAR se reutiliza en la parte espacial de los Tipos III y IV de interacción.

Lo único que cambia es $\delta_{s,t}$, producto de Kronecker de una estructura espacial ($\mathbf{I}_S$ o CAR $\mathbf{R}_s$) por una temporal ($\mathbf{I}_T$ o RW $\mathbf{R}_t$):

Modelo	$\delta_{s,t}$	Kronecker	Hipótesis sustantiva
Base	(sin interacción)	n/a	Curvas paralelas: el mapa no cambia de forma
Tipo I	$\mathcal{N}(0, \tau_\delta^{-1})$ iid	$\mathbf{I}_S \otimes \mathbf{I}_T$	Desviaciones estado-año = ruido sin forma
Tipo II	RW1 en t , indep. por estado	$\mathbf{I}_S \otimes \mathbf{R}_t$	Cada estado su propio calendario de tamizaje
Tipo III	CAR en s , indep. por año	$\mathbf{R}_s \otimes \mathbf{I}_T$	Mapa distinto cada año, sin memoria
Tipo IV	CAR en s + RW1 en t	$\mathbf{R}_s \otimes \mathbf{R}_t$	Mapa que evoluciona suave (difusión acoplada)

En el contexto mexicano cada tipo tiene una lectura concreta. **Tipo II** es la hipótesis natural si los quiebres de tendencia los manda la *política estatal* (el tamizaje mastográfico es competencia de cada entidad y cada una intensifica detección en su propio calendario). **Tipo IV** sería un proceso difusivo (un foco que contagia a vecinos y persiste), poco plausible para una enfermedad no infecciosa. **Tipo I** es la hipótesis nula de la interacción: las desviaciones de la aditividad son ruido de celda (sobredispersión Poisson, irregularidad del registro estado-año), sin estructura espacial ni temporal. **Tipo III** (choque espacial anual sin memoria) es el menos plausible a priori para cáncer; se incluye por completitud del marco.

Modelos reducidos anidados

Siguiendo a Knorr-Held §2.5, además de los cinco modelos de la familia se ajustan tres especificaciones reducidas que apagan bloques principales. Sirven para medir, por la caída de devianza, cuánto aporta cada bloque:

$$\begin{array}{lll}
\text{nulo:} & \log \lambda_{s,t} = \alpha & (\text{riesgo plano; sólo el intercepto}). \\
\text{solo tiempo:} & \log \lambda_{s,t} = \alpha + \gamma_t & (\text{tendencia nacional RW1, sin espacio}). \\
\text{solo espacio:} & \log \lambda_{s,t} = \alpha + \phi_s + \theta_s & (\text{convolución BYM, sin tiempo}).
\end{array}$$

Los tres comparten la misma verosimilitud Poisson con offset y los mismos hiperpriors $\text{Gamma}(1, 0, 1)$; cada uno es un submodelo estrictamente anidado del base, y el base a su vez de los cuatro tipos. La cadena de submodelos $\text{nulo} \subset \{\text{solo tiempo, solo espacio}\} \subset \text{base} \subset \text{Tipo I-IV}$ permite atribuir la devianza explicada a cada componente por separado (§11).

5. Modelos reducidos: la escalera de bloques

Antes de la familia completa se ajustan los tres submodelos anidados. Cada uno aísla un bloque y su devianza mide cuánto explica ese bloque por sí solo.

5.1. Modelo nulo ($\log \lambda = \alpha$)




Figura 4: Modelo nulo: traza, media ergódica y ACF de α .

Con un solo parámetro la convergencia es trivial ($\hat{R} = 1,00$, n_{eff} alto, ACF que cae de inmediato). El estimador es un riesgo plano: $\hat{\lambda}_{s,t} \equiv 0,9999$ para las 704 celdas, es decir, el modelo dice que toda entidad-año tiene el riesgo promedio del panel. Es un ajuste pésimo ($\bar{D} = 186,489,0$, $p_D = 1,0$): sirve únicamente como cota superior de devianza contra la cual medir el aporte de cada bloque. Su lectura sustantiva es nula por construcción, y ese es exactamente su propósito.

5.2. Solo tiempo ($\log \lambda = \alpha + \gamma_t$)




Figura 5: Solo tiempo: convergencia de α y τ_γ .

Converge limpio ($\hat{R} \leq 1,00$ en todos los nodos, 0 parámetros sobre 1,1): la RW1 escalar es fácil de muestrear y no hay competencia de identificabilidad. El coeficiente temporal γ_t recupera la curva nacional: $\exp(\gamma_t)$ pasa de 0,566 en 2003 a 2,377 en 2024, un factor de 4,2, idéntico en forma al de los modelos completos. Pero por sí solo el bloque temporal deja $\bar{D} = 129,938,4$: explica una caída de 56,551 unidades respecto al nulo, menos de un tercio de la heterogeneidad total. Interpretación: el crecimiento nacional del registro es real y fuerte, pero la mayor parte de la variación del cáncer de mama en México *no* es temporal, es geográfica y de celda.

5.3. Solo espacio ($\log \lambda = \alpha + \phi_s + \theta_s$)




Figura 6: Solo espacio: traza, media ergódica y ACF de α , τ_ϕ y τ_θ . Los marginales de τ_ϕ y τ_θ *no* mezclan: es la consecuencia esperada de la no identificabilidad BYM, no un fallo del muestreador.

Por qué τ_ϕ y τ_θ no convergen. El predictor entra en la verosimilitud sólo a través de la suma $\phi_s + \theta_s$: sumar una constante a ϕ y restarla a θ deja $\log \lambda_{s,t}$ exactamente igual. La verosimilitud informa entonces sólo $\phi_s + \theta_s$ (y, por extensión, la *precisión total* implícita); τ_ϕ y τ_θ son funciones del prior, no de los datos, y se intercambian varianza entre sí a lo largo de la cadena. Sin bloque temporal que absorba parte de la variación, esta indeterminación BYM aparece en su forma más pura y los dos marginales no se estabilizan: $\hat{R}$ máximo 1,58 con 34 de 771 nodos sobre 1,1, todos concentrados en la pareja τ_ϕ/τ_θ y unas pocas precisiones derivadas.

Las cantidades identificadas sí convergen. El intercepto α , la *suma* $\tau_\phi + \tau_\theta$ (la precisión espacial total, que es lo que la verosimilitud realmente informa) y, por consecuencia, $\exp(\phi_s + \theta_s)$ y $\lambda_{s,t}$ mezclan limpiamente. La Fig. 7 lo muestra para α y para $\tau_\phi + \tau_\theta$: trazas estacionarias, medias ergódicas planas y ACF que decae rápido. En lo que sigue tratamos el modelo **como si convergiera**, porque las cantidades sustantivas (las que se interpretan y se mapean) son justo las identificadas; la indeterminación BYM sobrevive únicamente en el reparto suave/ruido del prior, que no entra en la lectura.




Figura 7: Solo espacio, cantidades identificadas: traza, media ergódica y ACF de α (arriba) y de la precisión espacial total $\tau_\phi + \tau_\theta$ (abajo). Ambas mezclan limpiamente entre cadenas; son las cantidades que el modelo de hecho estima.

Con esa lectura, el bloque espacial explica más que el temporal: $\bar{D} = 107,222,3$ (79,267 unidades menos que el nulo), con un gradiente espacial (mayor en el centro-occidente y el norte, menor en el sureste y el sur), *más extremo* que en el base o en Tipo I porque, sin tiempo ni interacción, el bloque espacial es lo único que puede absorber toda la variación.

6. Modelo base (efectos principales, sin interacción)

6.1. Convergencia




Figura 8: Modelo base: traza, media ergódica y ACF de α , τ_ϕ y τ_γ (dos cadenas).

El ajuste usa 2 cadenas, 300,000 iteraciones, 50,000 de *burn-in* y adelgazamiento (*thinning*) de 250. **Las cadenas convergen y el modelo es utilizable:** $\hat{R}$ máximo 1,26, con 18 de 794 nodos sobre 1,1. El intercepto α está bien identificado: es la evidencia directa de que centrar θ (suma-cero, como Knorr-Held) resolvió la confusión de identificabilidad $\alpha \leftrightarrow \bar{\theta}$ que rompía la cadena en las primeras corridas. El residuo de dificultad recae en la pareja BYM τ_ϕ/τ_θ (sólo la suma $\phi_s + \theta_s$ está identificada, no cada componente), atenuada porque el bloque temporal absorbe parte de la variación. No invalida la inferencia sobre $\lambda_{s,t}$ ni sobre la devianza.

6.2. Qué estima el modelo base y lectura de sus parámetros

El base es un GLM jerárquico Poisson log-lineal: $\log \lambda_{s,t} = \alpha + \phi_s + \theta_s + \gamma_t$. Cada término tiene una lectura concreta y todos quedan estimados con los siguientes valores posteriores:

- **Intercepto α .** Nivel base del log-riesgo cuando todos los efectos (centrados a suma cero) valen cero. $e^\alpha < 1$ porque el offset usa la tasa promedio del periodo y, con la distribución sesgada a la derecha, el estado-año típico queda por debajo de esa media.
- **Efecto espacial total $\phi_s + \theta_s$.** Lo único identificado por los datos es la *suma* (ver nota BYM): $\exp(\phi_s + \theta_s)$ es el riesgo relativo de cada estado frente al promedio, un mapa fijo común a los 22 años. El reparto en parte suave (ϕ , ICAR) y ruido (θ , iid) lo fija el prior, no la evidencia, así que no se interpretan por separado. Las cifras por estado se dan para el modelo reportado (Tipo I, lectura en contexto, §7.3).
- **Tendencia temporal γ_t (RW1).** Curva nacional única; $\exp(\gamma_t)$ es el riesgo del año frente al año promedio del periodo. Sube de forma marcada de 2003 a 2024 con la caída de 2020 (cifras en §3 y §7.3).
- **Precisiones $\tau_\bullet$.** Inverso de la varianza de cada bloque: controlan cuánto se encogen sus efectos hacia cero y se estiman de los datos. τ_γ es alta (tendencia suave, incrementos anuales pequeños); τ_ϕ y τ_θ tienen intervalos anchos y reparto incierto (el síntoma BYM): hay variación espacial, pero su división suave/ruido no está identificada.

Al evaluar el ajuste: la devianza posterior media del base es $\bar{D} = 49,898,9$, frente a $\approx 5,900$ de los modelos con interacción. El modelo sin $\delta_{s,t}$ ajusta $\sim 44,000$ unidades de devianza peor. La razón es directa: con conteos de 4 a 7301 y varianza muy superior a la media, la Poisson aditiva no tiene dónde absorber la sobredispersión de celda; al forzar curvas paralelas, ningún $(\alpha, \phi, \theta, \gamma)$ puede reproducir que Colima 2024 tenga SMR 7,3 mientras la tendencia nacional ese año es $\approx 2,1$. Su $p_D = 56,4$ (el menor de la familia) confirma que es un modelo rígido. Conclusión: la interacción no es un refinamiento, es estructural.

7. Tipo I: interacción no estructurada

7.1. Convergencia




Figura 9: Tipo I: traza, media ergódica y ACF de α , τ_ϕ y τ_γ .

El ajuste usa 2 cadenas, 300,000 iteraciones, 50,000 de *burn-in* y adelgazamiento (*thinning*) de 250. La Fig. 9 muestra, para los hiperparámetros, las trazas, la media ergódica y la autocorrelación: las dos cadenas se superponen, las medias ergódicas se estabilizan y la autocorrelación cae pronto. **Las cadenas convergen y el modelo es utilizable:** $\hat{R}$ máximo 1,16, con sólo 3 de 1,499 nodos por encima de 1,1 (esos pocos son λ o δ de celdas con conteos diminutos, donde el posterior es legítimamente ancho). La precisión de la interacción τ_δ mezcla sin esfuerzo (bajo $\mathbf{I}_S \otimes \mathbf{I}_T$ los $\delta_{s,t}$ son condicionalmente independientes) y el intercepto α también; el único residuo de dificultad es la pareja BYM τ_ϕ/τ_θ , la no identificabilidad $\phi_s + \theta_s$ común a todos los modelos. La devianza está bien mezclada.

7.2. Lectura del modelo y sus parámetros




Figura 10: Tipo I, año 2024. Izquierda: $\hat{\lambda}_s$ vs. SMR cruda (la diagonal es identidad). Derecha: SMR cruda (gris) vs. riesgo suavizado (rojo, con IC95) ordenado.

Tipo I añade a la estructura del base un residuo $\delta_{s,t} \sim \mathcal{N}(0, \tau_\delta^{-1})$ independiente por celda. Sus efectos principales conservan la lectura del base, pero sus e^{ϕ_s} se acercan a 1 respecto al base porque δ se lleva la variación de celda. Por ajuste (Dbar) es el mejor (§11). **Tipo I prácticamente no suaviza.** En 2024 la correlación entre SMR cruda y $\hat{\lambda}$ es 1,000 y la discrepancia relativa media es 0,24 %: los puntos caen sobre la diagonal (Fig. 10) y el R^2 in-sample de conteos es 1,000. Esto indica sobreajuste: con $\mathbf{I}_S \otimes \mathbf{I}_T$ hay un $\delta_{s,t}$ por celda, esencialmente un parámetro por observación, de modo que δ absorbe la sobredispersión como residuo per cápita. El menor $\bar{D}$ se debe a que δ absorbe la sobredispersión, no a estructura espacio-temporal detectada. Sustantivamente, Tipo I es la afirmación de que las desviaciones de la separabilidad en el cáncer de mama mexicano son ruido idiosincrático de estado-año, sin patrón espacial ni temporal. Para una enfermedad no infecciosa, con registros de calidad heterogénea entre entidades y años, esa conclusión es epidemiológicamente plausible: no hay un contagio que difunda, hay 32 sistemas estatales de registro con su propio ruido.




Figura 11: Tipo I: trayectorias de $\hat{\lambda}_{s,t}$ (rojo) de las seis entidades que más se desvían de la tendencia nacional (gris discontinua); puntos azules = SMR cruda.

Las entidades que más se apartan de la tendencia nacional son estados *pequeños* (Colima, Aguascalientes, Campeche, Morelos) con saltos abruptos año a año (Colima $0,61 \rightarrow 7,25$; Aguascalientes con pico $5,56$ en 2016; Morelos $5,08$ en 2019; Campeche $3,76$ en 2014). $\hat{\lambda}$ persigue al SMR crudo (puntos azules) en vez de alisarlo: esos picos no tienen forma espacial ni persistencia temporal, son exactamente lo que un campo $CAR \times RW1$ trataría de suavizar y lo que Tipo I, en cambio, reproduce.

7.3. Lectura en contexto: efectos en casos

Los efectos están centrados (suma cero en espacio, tiempo e interacción), así que se leen como desviaciones *multiplicativas* respecto al promedio; el nivel base está en α . Por la convolución BYM sólo la suma $\phi_s + \theta_s$ está identificada, de modo que el efecto espacial se reporta como $\exp(\phi_s + \theta_s)$ (riesgo relativo total del estado frente al promedio), no ϕ_s ni θ_s por separado.

Tendencia temporal. $\exp(\gamma_t)$, riesgo relativo del año frente al año promedio del periodo, pasa de $0,55$ (2003) a $2,42$ (2024), un factor de $4,42$. El incremento de un solo año al final del periodo (2023 a 2024) es de $+6\%$: traducido a casos, a la población y al patrón espacial de 2024, ese único año añade $\sim 1,893$ casos registrados al total nacional (de $34,429$ casos ajustados en 2024).

Efecto espacial por estado. $\exp(\phi_s + \theta_s)$ es cuánto registra cada entidad por encima o por debajo del promedio nacional, a igualdad de año. Ciudad de México: $1,89$ ($+89\%$); su nivel espacial añade $\sim 1,664$ casos en 2024 frente a lo que registraría al promedio. Los nueve estados del norte promedian $1,33$ ($+33\%$): Sinaloa, por ejemplo, $+531$ casos en 2024 por su nivel. Los siete del sur promedian $0,75$ (-25%): Chiapas, -400 casos frente al promedio. Más alto: Jalisco $2,01$, Colima $2,00$, Ciudad de México $1,89$. Más bajo: Guerrero $0,35$, Tlaxcala $0,40$, Hidalgo $0,40$.

Interacción (residuo estado-año). En Tipo I $\delta_{s,t}$ no lleva restricción de centrado (su especificación es ruido iid), así que cada $\exp(\delta_{s,t})$ es el factor por el que ese estado-año se aparta de lo

que predicen los efectos separables. El caso más extremo es Morelos 2019: $\exp(\delta) = 4,14$, es decir, 1,234 casos ajustados frente a 298 sin ese término. No es señal espacio-temporal estructurada: es el residuo por celda que absorbe la sobredispersión.

7.4. ¿Por qué no suaviza, ni siquiera en celdas pequeñas? México vs. Ohio

La meta declarada de Knorr-Held es *suavizar* (“the goal here could be described as one of smoothing”), y en su marco el mapa suavizado es el λ *completo*, con la interacción estructurada incluida; el suavizamiento lo produce la estructura GMRF (*campo aleatorio markoviano gaussiano*) del prior (RW1/CAR), no un castigo sobre la precisión. Cabe entonces la pregunta: nuestros datos también tienen celdas escasas (hay celdas con 4 a 15 casos), ¿no deberían suavizarse al menos ahí?




Figura 12: SMR cruda (arriba) vs. riesgo del modelo ganador (centro) vs. modelo Base (abajo), 2003 y 2024. El ganador es indistinguible de la cruda; sólo Base, sin δ , suaviza.

La respuesta empírica es **no**. Partiendo las 704 celdas por cuartil de casos esperados E , en el cuartil *más escaso* ($E \leq 200$) la discrepancia relativa media entre $\hat{\lambda}$ y la SMR cruda es de apenas 4,5 % en Tipo I (y ~ 6 % en Tipo II), frente a **85 %** en Base. Concretamente, una celda con $y = 4$, $E = 126,8$ y SMR cruda 0,03 se queda en 0,06 con Tipo I, mientras Base la encoge a 0,20. La causa no es “los datos no son tan escasos como Ohio”: es estructural. Cualquier modelo con **un δ por celda** y precisión τ_δ estimada bajo el prior disperso *del propio paper* tiene libertad para interpolar cada observación; con conteos grandes la verosimilitud Poisson domina al prior GMRF y δ se pega al dato. Knorr-Held no observa esto en grado visible porque sus conteos de Ohio (mortalidad por una causa, celdas condado $\times$ edad) son chicos y escasos: ahí el GMRF domina y el suavizamiento es esencial. Con incidencia *registrada* mexicana a nivel estatal los conteos son grandes y precisos, así que hay poco ruido muestral que suavizar y el λ completo necesariamente cae sobre el mapa crudo (Fig. 12). Ese contraste se debe a los datos (conteos grandes), no a un defecto del modelo.

Base sí suaviza fuerte, pero *no* es el entregable: al carecer de δ no puede representar ninguna desviación estado-año real y lo fuerza todo a la estructura separable; por eso su devianza es muy alta (subajuste). El **Tipo IV**, con el mayor acoplamiento a priori (CAR en espacio y RW1

en tiempo, doblemente centrado), sería el candidato natural a suavizar celdas escasas, pero su corrida **no convergió** ($\hat{R} = 2,46$): no aporta evidencia. La conclusión descansa entonces en Tipo II y Tipo III, que sí convergen y *ninguno de los dos suaviza* (discrepancia $\sim 4\text{--}6\%$ en el cuartil de menor E): el acoplamiento GMRF queda dominado por la verosimilitud para estos datos *independientemente* del tipo de estructura.

8. Tipo II: dinámica propia por estado

8.1. Convergencia




Figura 13: Tipo II: convergencia de α , τ_ϕ y τ_γ .

El ajuste usa 2 cadenas, 60,000 iteraciones, 10,000 de *burn-in* y adelgazamiento (*thinning*) de 10; trazas, media ergódica y ACF en la Fig. 13. **Las cadenas convergen y el modelo es utilizable**: $\hat{R}$ máximo 1,16 con 5 de 764 nodos sobre 1,1. Los hiperparámetros mezclan de forma esencialmente perfecta ($\hat{R} \approx 1,00$ en α , τ_ϕ , τ_θ , τ_γ y τ_δ , con n_{eff} de miles), **incluida la pareja BYM** τ_ϕ/τ_θ , que es la dificultad de mezcla recurrente en los demás modelos. Los pocos nodos por encima de 1,1 están en γ_t y en λ de celdas de conteo diminuto, donde el posterior es legítimamente ancho. La interacción es estimable con holgura.

8.2. Lectura del modelo




Figura 14: Tipo II: riesgo de cada estado relativo a la media nacional del año, para las seis entidades con trayectoria propia más marcada.

Tipo II modela que cada entidad sigue su *propia* trayectoria temporal, sin contagio espacial, lo que modela de forma natural que el tamizaje mastográfico es competencia estatal y cada entidad intensifica detección en su propio calendario. El modelo es estimable y la hipótesis se puede leer: la Fig. 14 muestra, para las entidades con mayor desvío propio, trayectorias claramente *individuales* (arranques, picos y declives en años distintos, no sincronizados entre vecinos), justo lo que predeciría un proceso guiado por política estatal de detección y no por difusión geográfica.

El veredicto de selección no cambia. Por DIC, Tipo II ($DIC = 6,697,5$, $\bar{D} = 5,926,7$, $p_D = 770,8$) queda a 28,7 puntos del ganador (Tipo I). A nivel celda la variación dominante sigue siendo sobredispersión: igual que en Tipo I, aquí $\text{cor}(\text{SMR}, \hat{\lambda}) \approx 1$ y $R^2 \approx 1$ en 2024 (encogimiento nulo). La hipótesis del calendario estatal es estimable (δ tiene forma temporal por entidad), pero entre las estructuradas que sí convergen (II y III) ninguna supera a Tipo I bajo DIC. Tipo II es una hipótesis viable pero no preferida; Tipo IV, que sería el árbitro más exigente, no convergió y deja la comparación abierta.

9. Tipo III: mapa anual sin memoria

9.1. Convergencia




Figura 15: Tipo III: convergencia de α , τ_ϕ y τ_γ .

El ajuste usa 2 cadenas, 300,000 iteraciones, 50,000 de *burn-in* y adelgazamiento (*thinning*) de 250 (Fig. 15). **Las cadenas convergen y el modelo es utilizable:** $\hat{R}$ máximo 1,30 con sólo 5 de 1,499 nodos sobre 1,1; τ_γ y τ_δ convergen y el único residuo de dificultad es, una vez más, la pareja BYM τ_ϕ/τ_θ , no un problema del campo δ . Estructuralmente Tipo III re-estima un campo CAR espacial independiente en cada uno de los 22 años ($\delta_{\cdot,t} \sim \mathcal{N}_S(\mathbf{0}, \mathbf{Q}_\delta^{-1})$, sin memoria temporal), que compite con el ϕ_s del bloque principal; aun así, con esta corrida queda en un nivel utilizable.

9.2. Lectura del modelo

Es la hipótesis menos defendible a priori para cáncer (choques espaciales anuales que no se arrastran en el tiempo, propios de fenómenos sin persistencia), incluida por completitud del marco de Knorr-Held. Sus mapas anuales son interpretables, pero los datos confirman su irrelevancia: es el **peor** modelo de interacción tanto en ajuste ($\bar{D} = 5,939,5$, el mayor de los cuatro) como en complejidad efectiva ($p_D = 987,6$), y por tanto en DIC (6,927,2). Paga la complejidad más alta por la peor verosimilitud: estructurar el mapa por año sin memoria añade flexibilidad sin comprar ajuste, porque la señal de δ no tiene esa forma. Tipo III es, simplemente, la peor estructura de interacción para estos datos.

10. Tipo IV: mapa que evoluciona (difusión acoplada)

10.1. Convergencia




Figura 16: Tipo IV: convergencia de α , τ_ϕ y τ_γ .

Tipo IV no convergió. $\hat{R}$ máximo 2,46 con 44 de 2,203 parámetros sobre 1,1 ($\hat{R} > 2$ es “no converge”, no “converge mal”). Sus cifras se reportan por completitud y por su comparación nominal con el resto, pero **ninguna conclusión sustantiva se apoya en Tipo IV**: lo que el muestreador produce sobre δ no es la posterior, es ruido del propio MCMC.

10.2. Lectura del modelo

Estructuralmente, en Tipo IV el mapa espacial CAR *evoluciona* como caminata aleatoria en el tiempo, de modo que vecinos en espacio y en tiempo se prestan fuerza (un foco que se difunde y persiste). Es el supuesto de un proceso difusivo o contagioso, poco plausible para una enfermedad no infecciosa como el cáncer de mama. La lectura conjunta sobre los tres tipos que sí se estiman (I, II, III): *ninguna* estructura impuesta sobre δ mejora el ajuste-complejidad frente a tratarla como ruido (Tipo I). Tipo II (dinámica estatal) es viable pero no preferido; Tipo III es el peor. Con esta parametrización, lo que la comparación premia es el modelo que *no* impone suavidad (Tipo I). Esa victoria, sin embargo, es exactamente lo que la siguiente sección desmonta como artefacto del criterio.

11. Comparación de modelos




Figura 17: Izquierda: distribución posterior de la devianza D por modelo. Derecha: DIC relativo (etiquetas = DIC absoluto).




Figura 18: Escalera de devianza ($\bar{D}$, escala log) y DIC por modelo, del nulo a Tipo IV. Cada barra/punto es el aporte acumulado de añadir un bloque.

Aporte de cada bloque (modelos reducidos)

Siguiendo la idea de Knorr-Held §2.5 (y la bitácora conceptual del proyecto, §7) de *recortar el modelo* para cuantificar la aportación de cada componente, se ajustaron tres modelos reducidos anidados: sólo intercepto ($\log \lambda = \alpha$), sólo tendencia ($+\gamma_t$) y sólo espacio ($+\phi_s + \theta_s$, sin tiempo). La caída de devianza posterior media mide cuánto explica cada bloque (Fig. 18):

- **Intercepto solo:** $\bar{D} = 186,489,0$. Un riesgo plano para las 704 celdas es un desastre: deja sin explicar toda la heterogeneidad.
- **+ tendencia temporal:** $\bar{D} = 129,938,4$ ($\Delta = 56,551$). La curva nacional RW1 (el crecimiento $\times 4,42$) es real y grande, pero por sí sola explica menos de un tercio de la variación.

- **+ espacio (BYM, sin tiempo):** $\bar{D} = 107,222,3$ ($\Delta = 79,267$ respecto al nulo). El bloque espacial explica *más* que el temporal: la geografía del riesgo de cáncer de mama en México pesa más que su evolución promedio. (Conserva, eso sí, la dificultad BYM τ_ϕ/τ_θ en su forma más pura.)
- **Base (espacio + tiempo):** $\bar{D} = 49,898,9$. Combinar ambos bloques principales baja otras $\sim 57,000$ unidades; los efectos principales son aproximadamente aditivos en su aporte.
- **+ interacción (Tipo I):** $\bar{D} \approx 5,900,5$ ($\Delta \approx 43,998$). **El término de interacción, solo, explica casi tanta devianza como todo el bloque temporal completo**, y deja al modelo en una banda inalcanzable para cualquier especificación separable.

La lectura sustantiva: en el cáncer de mama mexicano *ningún bloque es prescindible*; tiempo, espacio e interacción aportan cada uno decenas de miles de unidades de devianza. El bloque espacial es el mayor aporte individual ($\Delta 79,267$ respecto al nulo, frente a $\Delta 56,551$ del temporal); la interacción reduce otras $\sim 43,998$ unidades sobre el modelo base.

La Fig. 17: la devianza posterior media del base ($\approx 49,900$) está muy por encima de la de los cuatro modelos de interacción ($\approx 5,900$). Primera conclusión: cualquier forma de interacción ajusta mucho mejor que la separabilidad; el modelo aditivo no describe estos datos.

La segunda conclusión es más fina. Entre los cuatro tipos las diferencias de DIC son pequeñas (rango 6,668,8–6,927,2) y el orden es **Tipo I < Tipo II < Tipo IV < Tipo III**. Esto invierte el resultado de Knorr-Held en los datos de Ohio (donde ganó el Tipo II): aquí gana la interacción *menos* estructurada. La razón es coherente con todo lo anterior: la complejidad efectiva crece con la estructura impuesta (p_D : 768,2 en I $\rightarrow$ 987,6 en III) sin comprar ajuste ($\bar{D}$ apenas mejora ~ 40 unidades de I a III), porque la señal de δ es ruido de celda y estructurarla sólo añade parámetros penalizados. Tipo III es el peor justamente porque paga la p_D más alta (CAR anual sin memoria) por el peor $\bar{D}$ de los cuatro.

La tercera conclusión es metodológica: **el DIC se lee junto con la convergencia**. Con las corridas en paralelo actualizadas, Tipo I, Tipo II y Tipo III convergen a un nivel utilizable (Tipo I el más limpio, 3 nodos sobre 1,1; Tipo III 5; Tipo II 5). **Tipo IV no convergió** ($\hat{R} = 2,46$): sus cifras aparecen en la tabla y la figura por completitud, pero no se interpretan. Las estructuradas (I, II, III) *se estiman y aun así no ganan*: Tipo I tiene la menor mediana de devianza y el menor DIC; Tipo II queda a 28,7 puntos y Tipo III es el peor.

11.1. Limitación del DIC: el ganador interpola

El ranking por DIC tiene un problema y conviene enfrentarlo de cara. Tipo I tiene $\delta_{s,t} \sim \mathcal{N}(0, \tau_\delta^{-1})$ iid: un parámetro libre por celda, sin acoplamiento entre celdas. Es sobredispersión observacional, no estructura espacio-temporal. El DIC mide qué tan bien predice el modelo los datos vistos, y le da la mejor calificación a quien más ajusta cada celda al dato: $\text{cor}(\text{SMR}, \hat{\lambda}) = 1,000$, $R^2 = 1,000$ para Tipo I (y para los otros tres tipos). WAIC, BIC y LOO premian lo mismo por la misma razón.

Para penalizar directamente la interpolación construimos un **WAIC marginalizado**: para cada celda $c = (s, t)$, en lugar de evaluar $\log \text{Pois}(y_c | \hat{\lambda}_c)$ reemplazamos $\delta_{s,t}$ por la media condicional de su prior dado el resto, $m_{s,t} = \mathbb{E}[\delta_{s,t} | \delta_{-(s,t)}]$, y calculamos $\log \text{Pois}(y_c | E_c \exp(\alpha + \phi_s + \theta_s + \gamma_t + m_{s,t}))$. Cada celda se predice así usando información de sus vecinas, no de sí misma. La forma de $m_{s,t}$ depende del tipo: $m_{s,t} = 0$ para Tipo I (el prior iid no acopla nada); promedio de los dos vecinos temporales para Tipo II (RW1 estatal); promedio de los vecinos espaciales del año t para Tipo III (CAR anual); combinación Kronecker de ambos para Tipo IV. Los modelos

sin δ (Base, solo espacio, solo tiempo, nulo) no tienen nada que marginalizar, así que su WAIC marginal coincide con su WAIC estándar.

Cuadro 1: Comparación de DIC y WAIC marginalizado para los ocho modelos. $\text{WAIC}_{\text{marg}}$ usa $m_{s,t} = \mathbb{E}[\delta_{s,t} \mid \delta_{-(s,t)}]$ (media condicional bajo el prior GMRF del tipo) en vez del $\delta_{s,t}$ posterior. Misma escala devianza, menor = mejor.

Modelo	DIC	WAIC marginalizado	$\hat{R}$ máx	$\#(\hat{R} > 1,1)$	#param
Tipo I	6,669	1,688,469	1,16	3	1,499
Tipo II	6,697	141,318	1,16	5	764
Tipo IV [†]	6,708	126,347	2,46	44	2,203
Tipo III	6,927	1,812,418	1,30	5	1,499
Base	49,957	55,980	1,26	18	794
Solo espacio	107,259	115,234	1,58	34	771
Solo tiempo	129,960	139,725	1,00	0	24
Nulo	186,490	187,200	1,00	0	1

[†] Tipo IV no convergió ($\hat{R} = 2,46$); su línea es nominal. La escala absoluta de $\text{WAIC}_{\text{marg}}$ no es comparable con la del DIC: la varianza pointwise se vuelve enorme al eliminar el $\delta_{s,t}$ propio, así que lo informativo es el orden, no la magnitud numérica.

El ranking entre los modelos de interacción se invierte: bajo DIC el orden es Tipo I < II < IV < III; bajo $\text{WAIC}_{\text{marg}}$ es Tipo IV < II < I < III. Tipo I pasa de ganador a penúltimo, exactamente el síntoma que el criterio fue construido para detectar: sin su propio $\delta_{s,t}$ no tiene forma de predecir cada celda, porque su δ iid no comparte información entre celdas. Tipo IV, el más estructurado (CAR×RW1), es el único que borra la ventaja de la interpolación.

Más relevante todavía: los modelos sin δ aparecen *arriba* de los cuatro de interacción bajo $\text{WAIC}_{\text{marg}}$. Base (efectos principales sin interacción) tiene $\text{WAIC}_{\text{marg}} = 55,980$, menor que cualquier tipo. La parte mecánica de eso es que no hay δ que quitar y por tanto no se penaliza; la parte sustantiva es que cuando se exige predecir cada celda con efectos principales más, a lo más, información estructurada de vecinos, la separabilidad alcanza. La interacción ya no es necesaria.

Una sola lectura, dos criterios. DIC y WAIC marginalizado contestan preguntas distintas y dan respuestas opuestas, ambas correctas en su propia escala:

- **DIC** (Knorr-Held): la separabilidad *no* se sostiene; $\delta_{s,t}$ baja la devianza en $\sim 44,000$ unidades sobre Base y Tipo I (interpolador) es el mejor ajuste.
- **WAIC marginalizado**: la separabilidad *sí* alcanza; Base gana a los cuatro tipos y la mejora del DIC es sobreajuste celda-a-celda más que estructura espacio-temporal real.

Las dos lecturas conviven sin contradicción: $\delta_{s,t}$ es necesario para *replicar* los conteos observados (lo que el DIC mide), pero no es necesario para *predecirlos a partir de su contexto* (lo que el WAIC marginalizado mide). La descripción sustantiva del riesgo en México la dan los efectos principales.

12. Conclusiones

El predictor separable se sostiene; lo que falla es Poisson puro. El predictor $\alpha + \phi_s + \theta_s + \gamma_t$ de Base es separable; el predictor de Tipo I sólo le agrega un residuo iid por celda ($\delta_{s,t} \sim \mathcal{N}(0, \tau_\delta^{-1})$, sin estructura espacial ni temporal). Que Tipo I gane DIC sobre Base significa que los conteos están **sobredispersos respecto a Poisson**, no que haya un patrón espacio-tiempo no separable: el componente que mejor describe las desviaciones es ruido por celda, no estructura. Bajo WAIC marginalizado los efectos principales (Base) son lo único que se necesita para predecir cada celda desde su contexto. En suma, dos criterios y la misma conclusión estructural: no hay evidencia de interacción espacio-temporal genuina; sólo sobredispersión.

Tipo IV: la prueba que falta. El único de los cuatro tipos con un prior que efectivamente codifica difusión espacio-temporal (CAR×RW1) es Tipo IV. Si convergiera y ganara a Tipo I por DIC o a Base por WAIC marginalizado, sería evidencia genuina de inseparabilidad estructurada. Su corrida actual **no convergió** ($\hat{R} = 2,46$): no podemos descartar la hipótesis de inseparabilidad con la información del proyecto. Lo único que se concluye hoy es que II y III (las otras dos estructuradas) no superan al ruido de Tipo I. La conclusión queda condicional: con los modelos que sí estimamos, los datos prefieren “separable + sobredispersión” a cualquier interacción estructurada; queda abierto si un Tipo IV bien mezclado cambiaría esta lectura.

Lo que sí está bien identificado. Dos señales atraviesan todos los modelos y son robustas. Primero, la *tendencia nacional*: el riesgo relativo $\exp(\gamma_t)$ pasa de 0,55 (2003) a 2,42 (2024), un aumento de 4,42×, cruzando 1 alrededor de 2013, con una caída en 2020 ($\exp \gamma_{2020} \approx 1,16$ tras 1,45 implícito en 2019) y rebote posterior: la huella del subdiagnóstico por COVID-19 sobre el tamizaje. Segundo, el *efecto espacial total* $\exp(\phi_s + \theta_s)$ del Tipo I (la suma, que es lo identificado; no ϕ_s ni θ_s por separado): alto en el centro-occidente y norte (Jalisco 2.01, Colima 2.00, Ciudad de México 1.89) y bajo en el sureste y el sur (Guerrero 0.35, Tlaxcala 0.40, Hidalgo 0.40), consistente con el gradiente de urbanización y acceso a diagnóstico para cáncer de mama. La descomposición suave/ruido la fija el prior, no los datos, así que sólo se interpreta el total. Esta es **incidencia registrada**: el gradiente probablemente combina riesgo real (urbanización, factores ambientales y demográficos asociados al centro-occidente y al norte) y acceso a tamizaje/registro (CDMX y el norte tienen mayor cobertura mastográfica; en el sur el subdiagnóstico es plausible). Estas dos componentes no se pueden separar con los datos del proyecto.

Lo que no se rechaza es la separabilidad del predictor. El predictor de Tipo I es $\log \lambda_{s,t} = \alpha + \phi_s + \theta_s + \gamma_t + \delta_{s,t}$ con $\delta_{s,t} \sim \mathcal{N}(0, \tau_\delta^{-1})$ iid: la parte separable $\alpha + \phi_s + \theta_s + \gamma_t$ y un residuo *sin estructura espacial ni temporal*. Que Tipo I gane al resto significa que la sobredispersión es la mejor explicación de las desviaciones celda a celda, no que haya interacción espacio-tiempo detectable. Lo que el ajuste de Base rechaza (vía DIC) es estrictamente el **supuesto Poisson** sobre los conteos; lo que el WAIC marginalizado confirma es que el *predictor* separable basta para describir y predecir el riesgo. La frase “no es separable” debe leerse entonces como “los conteos están sobredispersos respecto a Poisson”, no como “hay un patrón espacio-tiempo no separable”.

Recomendación según uso.

- **Maapeo y descripción sustantiva del riesgo:** el Base es probablemente el modelo más útil. Da el mapa espacial suavizado que *efectivamente suaviza* ($\text{cor}(\text{SMR}, \hat{\lambda}) \approx 0,85$), gana bajo WAIC marginalizado, y su interpretación es la más limpia: tendencia nacional, gradiente espacial y nada más. Es el modelo que un informe de salud pública debe reportar como representación del riesgo.
- **Ajuste celda a celda y diagnóstico de sobredispersión: Tipo I** es el mejor ajustador (DIC mínimo y converge). Útil para detectar celdas extremas y cuantificar la sobredispersión observacional, no para mapear: $R^2 \approx 1$, encogimiento nulo, $\hat{\lambda}$ replica la SMR cruda.

- **Hipótesis de interacción genuina: Tipo IV** (CAR×RW1) es el único candidato a representar una verdadera estructura espacio-temporal. Su corrida actual no convergió ($\hat{R} = 2,46$). Si un rerun en paralelo converge, Tipo IV merecería ser el modelo de referencia: bajo WAIC marginalizado es el mejor de los cuatro tipos, y su prior sí impondría suavizado a celdas escasas en un régimen de conteos menores. En el régimen de incidencia registrada de México 2003–2024 la verosimilitud domina al prior, así que el suavizado probablemente seguirá siendo modesto.

Aportación del proyecto. Tres resultados sólidos sobreviven a la comparación entre criterios: (i) la **tendencia nacional** $\exp(\gamma_t)$ ($0,55 \rightarrow 2,42, 4,42\times$, con caída 2020 por COVID); (ii) el **gradiente espacial total** $\exp(\phi_s + \theta_s)$ (alto en centro-occidente y norte, bajo en sureste y sur), entendido como combinación no separable de riesgo real y de acceso a tamizaje/registro; (iii) la **ausencia de estructura espacio-temporal no separable detectable entre los modelos que sí convergen**: las desviaciones celda-año son consistentes con sobredispersión, no con difusión ni dinámica estatal estructurada. Esta conclusión queda condicional a un Tipo IV bien mezclado: es el único de los cuatro cuyo prior efectivamente codifica difusión espacio-temporal, y un rerun convergido podría revisar la lectura. La aportación del enfoque de Knorr-Held aquí no es elegir el modelo más vistoso sino cuantificar que, con los modelos estimables, la *estructura* espacio-temporal del cáncer de mama mexicano es indistinguible de sobredispersión por celda, y por qué eso difiere de Ohio.